资源约束下的小型语言模型实验报告

Resource Constrained Language Modeling

DASE7506 MP1 Small Language Model Challenge

姓名 LIU HONGJIANG 学号 3036707941

班级 Section 1A 提交日期 9.30

摘要 Abstract

本实验在课程固定的 WikiText-2、BPE-2048 分词器与独立 256-token 窗口下，组合小型因果 Transformer、窗口内 pointer 与训练集统计语言模型。最终采用 6 层、宽度 320 的网络，将前馈网络低秩因子的秩从 144 扩展到 176，并在相同新增训练目标预算下与控制组比较。扩容使验证 BPB 相对匹配控制组降低 0.001428；冻结后正式 CPU FP32 测试 BPB 为 1.455264。CPU 时间为同机基线的 4.4967 倍，峰值内存 1.6921 GiB，完整推理资产 54.9695 MiB，三项实测均低于课程上限。辅助损失与优化器状态续接未显示明显额外收益。报告同时披露训练成本、既往测试暴露、数值审计例外与复现边界。

This project combines a compact causal Transformer, a within-window pointer, and training-derived n-gram statistics under the fixed course evaluation protocol. The final model has six layers and width 320. Increasing the feed-forward factorization rank from 144 to 176 improves validation BPB by 0.001428 over a matched-target control. The frozen model achieves 1.455264 full-test BPB in CPU FP32, with a measured runtime ratio of 4.4967, peak RAM of 1.6921 GiB, and 54.9695 MiB of inference assets. Auxiliary loss and optimizer-state retention provide negligible gains in these comparisons. Training costs, prior test exposure, numerical exceptions, and reproduction limits are disclosed. These single-trajectory results do not establish statistical significance across seeds.

关键词 Keywords 语言建模 BPB 因果缓存 低秩扩容 资源约束

核心结果 Key Results

指标 Metric	结果 Result
正式 test BPB	1.455264035047553
完整 validation BPB CPU FP32	1.4372712027965369
参数量 Parameters	6,279,315
最终实现 Implementation	push150_expand ｜ push152-expanded

模型和评分包在本报告编写期间保持不变。

1 任务与评测协议 Task and Protocol

课程目标是在轻量 CPU 推理预算内降低完整测试集的 bits per byte（BPB）[1]。使用课程提供的 WikiText-2 固定划分；相关语料背景见 Merity 等 [2]。不增加外部文本或预训练权重，分词器、数据文件和官方评价函数保持原始字节。

1 1 指标与数据 Metric and Data

$$BPB = \frac{NLL\ in\ nats}{ln(2) \times UTF8\ bytes}$$

其中 NLL 为所有有效 next-token 目标的自然对数负似然总和；分母使用整个原始划分的 UTF-8 字节数，包含首 token 对应字节。BPB 越低越好；token perplexity（PPL）与 BPB 不同，也不能直接与文献中的词级 PPL 比较。

划分 Split	预测目标 Targets	原始字节 UTF8 bytes
Train	3,613,343 个 token[1]	10,951,562
Validation	376,599	1,148,007
Test	428,405	1,292,013

[1] Train 数字为编码后的 token 总数，不是训练期间随机窗口累计处理目标数；这两个成本口径不能混用。

评价使用独立的 256 个目标窗口，最后不足长度的窗口也计入。相邻窗口可共享边界输入 token，但不能携带隐藏状态或前缀缓存。每个划分除首 token 外的目标只计分一次。模型接口只接收输入 ids，不接收参考目标；官方评分器在模型输出后取出正确目标的概率。

1 2 资源边界 Resource Budget

项目	课程上限	本报告核算口径
CPU 时间	基线的 5 倍	同机 CPU FP32 完整评分
峰值内存	4 GiB	整个评分进程工作集
推理资产	64 MiB	完整必需资产的未压缩字节

训练时长和架构选择没有固定上限，但必须披露成本。评分时的 64 MiB 不用压缩 ZIP 大小代替，也不把单独的训练依赖或独立基线误算成候选推理所需资产。本报告区分训练成本、开发验证遍历与最终评分。

1 3 选择与冻结 Selection and Freeze

本轮 push152 先固定训练菜单和至少 0.001 验证改善的门槛，完成全部候选后按完整 validation 排序，再对资源合格者冻结。额外 push153 动态混合筛选也在最终 test 前封存。最终候选仅做一次完整 test，前后各测一次固定基线，不根据这次 test 重选或调整模型。历史测试暴露的限制见第 6 节。

2 模型与因果机制 Model and Causality

神经主干采用 decoder-only Transformer，使用旋转位置编码 RoPE [3]、RMSNorm [4] 和 SwiGLU 前馈层 [5]。这些已有组件作为实现基础；本报告的主要受控实验考察固定推理预算下的 FFN 容量扩展，不把已有组件称为本项目原创。

结构项 Component	最终设置 Final setting
层数 宽度 注意力头	6 | 320 | 8，每头维度 40
词表 上下文	2048 | 256
SwiGLU 隐藏维度	864，不是低秩因子秩 176
QKV 联合投影 attention 输出	rank 160 | dense
FFN gate value out	三个投影的 rank 均为 176
嵌入与输出头	共享同一参数 tied weights

2 1 两级概率混合 Probability Mixture

$$Q_t(v) = (1 - g_t)N_t(v) + g_t C_t(v)$$
$$P_t(v) = 0.85\, Q_t(v) + 0.15\, M_t(v)$$

N 是神经 softmax 分布，最终推理温度固定为 1.3；C 是当前窗口内 pointer 分布；g 是学习得到的门控且限制在 0 至 0.5。M 是最高 5 阶的 Modified Kneser–Ney（MKN）统计模型 [6]，折扣 scale 为 0.7。pointer 与统计模型分别提供当前前缀的重复信息和训练语料的局部搭配信息，这只是机制动机，不能替代消融证据。

2 2 为什么没有读取未来 Causal Boundary

预测位置 t 时，pointer 只对 j < t 的历史特征分配注意力，复制的值是输入中的 x[j+1]，因此最大只到已观察到的 x[t]，并不包含待预测的 x[t+1]。首位置没有可复制历史，门控强制为零。注意力中学习相似度与有符号距离偏置；“有符号”作用于距离偏好，不产生负概率。

主干 attention 使用因果掩码。MKN 查询键只由当前样本的已见前缀形成；可复用的静态索引仅由冻结的训练计数构建，不保存评测窗口前缀。每个样本、窗口和评分调用相互独立，预测函数不进行网络访问或读入参考答案。

2 3 统计表与内存 Tables and Memory

最终 21 个统计 buffer 全部继承自自训练父模型，并经逐位一致性核验。本轮不重新计数。历史表仅从 train 构建，并在高阶条目剪枝后把删除的概率质量回退到低阶，而不是重新归一化剩余高阶计数。统计表、神经权重和全部必需源码均纳入推理资产清单。

3 训练设计与对照 Training Design

本轮固定 5 条训练分支，共同历史祖先累计处理 638,976,000 个训练目标。训练从本项目已有的自训练权重继续，不使用外部预训练模型。不同分支对祖先成本的复用必须披露，不能把续训标为从零开始。

3 1 阶段 A 优化器状态 Optimizer State

从同一份原始权重、EMA、采样器和随机数状态分出两支：保留原 Muon/AdamW 状态，或重置优化器。两支均以相同固定低学习率训练 8,000 步，每步 8,192 个目标，共新增 65,536,000 个目标。既有 EMA .99 延续；EMA .999 从既有 EMA .99 初始化，不宣称其历史上就是 .999。每支固定 14 个完整验证选择。

3 2 阶段 B 容量与损失 Capacity and Loss

三支均使用 seed 193、相同随机训练窗口起点流、20,000 步与新优化器，分别为 control、auxiliary 和 expanded。每支新增 163,840,000 个目标，EMA .99；每支固定 11 个完整验证选择。辅助损失将 10% 权重分给 neural-only NLL，另 90% 为 neural-plus-pointer NLL，两项共用同一组标签。

设置	Control	Auxiliary	Expanded
FFN 因子秩	144	144	176
辅助 NLL 系数	0	0.1	0
新增训练目标	163.84M	163.84M	163.84M
可训练参数	5,597,331	5,597,331	6,279,315

扩容涉及 6 层各 3 个 FFN 投影，共 18 对低秩矩阵。保留旧因子分量，新左因子用固定 seed 随机初始化，新右因子为零；代数函数不变，FP32 初始预测已按预声明容差核验。扩容初始化时逐位复制 QKV 与 dense attention 输出权重，后续照常训练；只有统计表全程冻结。初始化资源检查在本轮任何 GPU 训练前完成。

3 3 共同训练设置 Shared Recipe

超参数	数值
批次与长度 训练精度	32 × 256 | GPU BF16
Dropout 训练温度 推理温度	0.2 | 1.15 | 1.3
优化器 梯度裁剪	Muon + AdamW | 1.0
B 阶段初始学习率	backbone 7.5e−6；pointer 7.5e−5；scalar 2.5e−4；Muon 5e−4
B 阶段调度 EMA	cosine，warmup 200，floor 0.1 | 0.99

最终分支只优化 neural-plus-pointer NLL，固定 MKN 表不进入训练损失。完整调度、优化器分组和采样以冻结源码及 push152_plan.json 为准。相同目标数不是相同 FLOPs；扩容模型有更多参数。Muon 的复用和许可见第 8 节 [7]。

4 实验结果与消融 Results and Ablation

4 1 最终成绩 Final Score

模型	训练谱系目标数	完整 test BPB
课程 GPT 基线	9,830,400	2.1012604381
上一冻结版本 push151	638,976,000	1.4574724554
最终版本 push152	802,816,000	1.4552640350

最终模型相对上一冻结版本的 test BPB 降低约 0.00220842。基线与最终模型的训练目标预算不同，因此不能把两者成绩差解释为同预算架构提升。历史 test 分数仅作结果披露；本轮受控因果比较使用下表的 validation 端点。

4 2 相同预算下的关键消融 Matched Target Ablation

B 阶段 20k 端点	Raw 验证 BPB	EMA 验证 BPB
Control rank 144	1.4391976643	1.4386994835
Auxiliary α 0.1	1.4391915885	1.4386843682
Expanded rank 176	1.4377456262	1.4372712466

扩容相对 control 的 EMA BPB 降低 0.00142824，raw 也降低 0.00145204；两个端点方向一致，支持本条训练轨迹上 FFN 容量增加有用。辅助损失仅降低约 0.00001512，没有明显实质优势。该对照同时满足相同目标预算比较与去掉扩容机制的消融，但没有覆盖每个历史组件，也没有多 seed 重复。

A 阶段保留/重置优化器的最终 EMA .999 验证 BPB 分别为 1.4391854848 和 1.4391858732，差约 3.88e−7。在本设置下，保留历史优化器状态没有可辨识优势。最佳快照的选择记录与最终固定预算比较分别保留，避免用不同早停步数替代受控对照。

4 3 未采用的动态混合 Rejected Dynamic Mixture

固定 κ 菜单	完整验证 BPB	相对 control 改善
关闭 control	1.4372712466	0
8	1.4366724863	0.0005987603
32	1.4367922199	0.0004790268
128	1.4369636705	0.0003075761

动态混合仅利用已观察输入更新窗口内专家权重。κ=8/32/128 的验证改善均未达到预先固定的 0.001 门槛，因此全部拒绝，未测 test，也未纳入最终资源审计。

5 资源与正确性核验 Resources and Checks

5 1 同一冻结模型的资源 Measured Resources

指标	实测	课程上限
候选完整 test 评分时间	37.1141444 秒	按同机基线比较
前后基线时间	8.2034678 / 8.3038567 秒	同机同协议
候选 / 基线均值	4.496688 倍	5 倍
候选 / 更快基线	4.524202 倍	同时披露
正式评分峰值 RAM	1.692055 GiB	4 GiB
完整未压缩推理资产	54.969528 MiB	64 MiB

测量使用 CPU FP32、4 线程、affinity mask 15，前基线、候选、后基线分别在新进程运行。峰值内存覆盖评分进程和固定数据加载。测试前的三对交替 validation 计时中位数比值为 4.672761；保留所有计时，不仅报告最快值。不同 CPU 的相对开销可能不同，复核者仍需本机重测。

5 2 文件与老师提供的检查 File and Contract Checks

重新校验原始清单后，三个数据划分、tokenizer、数据 manifest、common.py、evaluate.py、model.py 和老师的 test_contract.py 哈希一致。最终 checkpoint 与全部推理依赖符合资产清单。评分包 837 项和补充包 68 项文件均完成逐项哈希核验。

冻结前代码单元测试 605 项通过，审计元数据测试另 36 项；加入额外研究代码后的评分包单元测试为 648 项通过。随后保持老师原始五项测试方法及容差，仅将测试模型初始化替换为最终训练权重，5/5 通过：因果性、概率归一化及样本独立性、窗口重置、梯度有限性、目标计数。此检查只用合成输入，没有重新评分 test。

5 3 短前缀浮点例外 Numerical Exception

额外短前缀/长窗口比较在 atol=5e−6、rtol=1e−6 下有 30 个 log-prob 元素超差，最大绝对差 1.57356e−5；老师原始五项测试仍 5/5 通过。补充容差 atol=rtol=1e−5 通过。

独立 neural/pointer FP64 参考的最大前缀差为 2.84217e−14；未来输入扰动、样本独立性、重置与 MKN 前缀检查一致。这支持“矩阵归约导致 FP32 微差”的解释，但不代表课程批准额外容差；正式评分仍为 FP32。

6 成本与局限 Costs and Limitations

6 1 训练与搜索成本 Compute Accounting

口径	数量或时间
最终分支共同祖先目标数	638,976,000
最终分支本轮新增目标数	163,840,000
最终分支累计谱系目标数	802,816,000
push152 五支新增搜索目标总数	622,592,000
五支训练循环计时合计	3,196.19872 秒，约 53.27 分钟
训练进程墙钟合计	3,243.39921 秒
训练过程完整验证选择	61 次

训练循环计时包含循环内的验证工作，不是纯梯度计算时间，也不是全部项目墙钟。扩容预检另含 6 次完整验证计时；最终资源审计另含 1 次完整验证与 6 次计时。push153 额外产生 4 个完整验证选择，但只共享执行 1 次专家遍历，共 46 批、6.04545 秒；没有新增梯度目标或统计扫描。

EMA 快照不会新增梯度目标。辅助损失复用同一批标签，额外损失项覆盖 163,840,000 次标签暴露，但不把采样目标数重复计算。历史统计表曾扫描 train 的 3,613,343 个 token；“本轮零新统计扫描”不等于整个项目没有计数工作。

更早的 push150 搜索已记录 753,664,000 个新增神经训练目标发生次数，以及 21,665,280 个门控梯度标签；其他历史搜索成本未穷尽重建。祖先复用、早期失败和未采用候选不能因最终只保留一个模型而从成本中抹去。

6 2 历史暴露与统计局限 Limitations

本轮 push152 的候选、超参数与 checkpoint 选择均仅依据完整 validation，并在正式 test 前冻结；更早冻结版本曾报告过 test 成绩，但 push152 不依据其 test 结果重选候选或调参。因历史上存在 test 暴露，本报告仅将其作为既往结果披露，不把它作为本轮因果比较证据。

实验只覆盖固定语料、固定 tokenizer、256-token 窗口和有限配置，主要比较来自单个 seed 及共享祖先。大量验证选择也存在验证过拟合风险。当前结果不证明普遍最优，不保证换硬件的计时比例相同，也不代表能在未见新数据上保持同样收益。 结论：在已测资源范围内，FFN 扩容分支取得最佳合格验证结果，正式 BPB 固定为 1.455264。实验提供直接评分复现、同目标预算的容量消融及资源和数值诊断证据。辅助损失分支虽通过相对父模型的改善门槛，却没有显示相对匹配 control 的实质优势；A 阶段和动态混合候选未达到门槛，因此均未选择为最终版本。

7 复现与材料 Reproduction and Artifacts

最终模型不重训即可评分。使用原始课程数据与冻结评分包；CPU 参考环境为 Windows、Python 3.12.14、PyTorch 2.7.1、numpy 2.5.3、tokenizers 0.21.4。GPU 训练使用 PyTorch 2.7.1 的 CUDA 环境与 BF16，评分必须使用 FP32。安装可联网，评分无需网络。

7 1 评分命令 Evaluation

将原始 wikitext_train.txt、wikitext_validation.txt 和 wikitext_test.txt 放入 code_overlay/data，进入 code_overlay。安装依赖后执行以下命令；完整基线配对计时步骤见随附 README。

```
python -m pip install torch==2.7.1 --index-url https://download.pytorch.org/whl/cpu
python -m pip install numpy==2.5.3 tokenizers==0.21.4
python evaluate.py --checkpoint
  runs/push152-expanded/validation-session000-step00020000-ema.pt
  --device cpu --threads 4 --precision fp32 --split test
```

上面的评分命令换行仅为排版，执行时合并为一行。预期正式结果为 1.455264035047553；权重 SHA256 如下。不同环境下可能有微小浮点差异，不应通过调参追逐最后几位。

```
752beccd552870a2f83dd5a460e1d1eb37ee0e809ecf40d6cac632222776bac5
```

7 2 训练复现范围 Training Scope

独立训练支持包提供本项目自训练的 push151 父权重、保持初始预测的 expanded 初始化权重及冻结训练代码，支持在新目录重放 B 阶段三组 20k 步对照。共同祖先训练量明确计入谱系，父权重不是外部预训练模型。支持包是训练依赖，不是候选评分时必须加载的资产。

完整历史包含多轮训练、校准、平均与统计构建。最早随机初始化阶段的 train_bold.py 与当前保留版本哈希不同，因此本材料不声称整条历史可逐字节端到端重放；B 阶段三组 20k 对照可由支持包重放。GPU 非确定性也意味着重训 checkpoint 的 SHA 不保证相同，正式成绩以附带冻结权重的直接评分为准。

8 AI 协助与参考文献 AI Assistance and References

本项目使用 Codex 提供实质 AI 协助，包括方法讨论、程序编写、实验执行、数值和资源核验及报告起草。课程代码、数据来源与开源许可均保留。Muon 复用遵循 MIT 许可，Copyright (c) 2024 Keller Jordan [7]。

[1] DASE7506. MP1 Small Language Model Challenge. 课程 GUIDE 与原始评测代码，2026。https://xudongwu-0.github.io/courses/dase7506/

[2] Merity S, Xiong C, Bradbury J, Socher R. Pointer Sentinel Mixture Models. 2016. https://arxiv.org/abs/1609.07843

[3] Su J, et al. RoFormer Enhanced Transformer with Rotary Position Embedding. 2021. https://arxiv.org/abs/2104.09864

[4] Zhang B, Sennrich R. Root Mean Square Layer Normalization. 2019. https://arxiv.org/abs/1910.07467

[5] Shazeer N. GLU Variants Improve Transformer. 2020. https://arxiv.org/abs/2002.05202

[6] Chen S F, Goodman J. An empirical study of smoothing techniques for language modeling. Computer Speech & Language, 1999, 13(4): 359–394. https://doi.org/10.1006/csla.1999.0128

[7] Jordan K. Muon optimizer. MIT license. https://github.com/KellerJordan/Muon